

Régressions avec résidus ARCH

Jean-Baptiste DURAND Ollivier TARAMASCO

18 avril 2013

Modèle

Notations

- $\theta \in \mathbb{R}^n$ est l'ensemble des paramètres du modèle.
- $\beta \in \mathbb{R}^q$ est l'ensemble des paramètres de la distribution conditionnelle.
- $\phi \in \mathbb{R}^p$ est l'ensemble des paramètres de l'espérance et/ou de la variance conditionnelle.

On a donc

$$\begin{aligned}\theta &= \begin{pmatrix} \phi \\ \beta \end{pmatrix} \\ n &= p + q\end{aligned}$$

Modèle

Processus

- $Y(t) | \mathcal{I}_{t-1} = m(t; \theta) + \sigma(t; \theta) \varepsilon(t; \beta) = m(t; \theta) + U(t; \theta)$
- $m(t; \theta)$: espérance conditionnelle.
- $\sigma(t; \theta)^2 = h(t; \theta)$: variance conditionnelle.
- $U(t; \theta)$: résidu (processus de type ARCH “pur”).
- $\varepsilon(t; \beta)$: bruit blanc, variance 1.

Remarque : Les $\varepsilon(t; \beta)$ sont i.i.d. Pas les $U(t; \theta)$ ni les $Y(t)$.

Vraisemblance

Calcul

On observe une trajectoire $\{y(t), t = 1 \dots T\}$ du processus Y .

La vraisemblance s'écrit :

$$\ln L(\theta, y) = \sum_{t=t_0}^T l(t; \theta, y)$$

$$\begin{aligned} l(t; \theta, y) &= -\ln \sigma(t; \theta) + \ln f_{\varepsilon} \left(\frac{y(t) - m(t; \theta)}{\sigma(t; \theta)} ; \beta \right) \\ &= -\ln \sigma(t; \theta) + \ln f_{\varepsilon} \left(\frac{u(t; \theta)}{\sigma(t; \theta)} ; \beta \right) \\ &= -\ln \sigma(t; \theta) + \ln f_{\varepsilon} (e(t; \theta) ; \beta) \end{aligned}$$

où $f_{\varepsilon}(x; \beta)$ est la densité de la variable aléatoire $\varepsilon(t; \beta)$ (qui dépend des paramètres β)

Vraisemblance

Densité du bruit

Si $\varepsilon(t; \beta)$ est la variable centrée réduite d'un variable $\nu(t)$ de loi connue de paramètre β :

$$\varepsilon(t; \beta) = \frac{\nu(t) - m_\nu(\beta)}{\sigma_\nu(\beta)}$$

avec $m_\nu(\beta) = E[\nu(t)]$ et $\sigma_\nu^2(\beta) = \text{var}[\nu(t)]$, on a :

$$\ln f_\varepsilon(x; \beta) = \ln \sigma_\nu(\beta) + \ln f_\nu(\sigma_\nu(\beta)x + \mu_\nu(\beta); \beta)$$

par exemple, si $\nu(t) \rightsquigarrow St(n)$, alors $\beta = n$, $m_\nu(n) = 0$,

$\sigma_\nu(n) = \sqrt{\frac{n}{n-2}}$ et donc :

$$\ln f_\varepsilon(x; n) = \frac{1}{2} \ln \frac{n}{n-2} + \ln f_{St(n)}\left(\sqrt{\frac{n}{n-2}}x\right)$$

Gradient

Calcul

$$\text{grad}_{\theta} \ln L(t; \theta, y) = \sum_{t=t_0}^T \text{grad}_{\theta} l(t; \theta, y) \quad (\text{Eq 1})$$

$$\begin{aligned} \text{grad}_{\phi} l(t; \theta, y) &= -\frac{1}{\sigma(t; \theta)} \text{grad}_{\phi} \sigma(t; \theta) \\ &\quad + \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(t; \theta), \beta) \text{grad}_{\phi} e(t; \theta) \quad (\text{Eq 2}) \end{aligned}$$

Gradient

Calcul suite ...

$$\begin{aligned} \text{grad}_{\beta} l(t; \theta, y) &= -\frac{1}{\sigma(t; \theta)} \text{grad}_{\beta} \sigma(t; \theta) \\ &\quad + \frac{\partial \ln f_{\varepsilon}}{\partial \mathbf{x}}(\mathbf{e}(t; \theta), \beta) \text{grad}_{\beta} \mathbf{e}(t; \theta) \\ &\quad + \text{grad}_{\beta} \ln f_{\varepsilon}(\mathbf{e}(t; \theta), \beta) \quad (\text{Eq 3}) \end{aligned}$$

$$\begin{aligned} \text{grad}_{\theta} \mathbf{e}(t; \theta) &= \frac{1}{\sigma(t; \theta)} [\text{grad}_{\theta} u(t; \theta) \\ &\quad - \mathbf{e}(t; \theta) \text{grad}_{\theta} \sigma(t; \theta)] \quad (\text{Eq 4}) \end{aligned}$$

$$\text{grad}_{\theta} u(t; \theta) = -\text{grad}_{\theta} m(t; \theta) \quad (\text{Eq 5})$$

Gradient

Simplifications

Parfois le calcul est plus simple si on dérive $h(t; \theta) = \sigma(t; \theta)^2$ (ex. GARCH) ou $\nu(t; \theta) = \ln \sigma(t; \theta)$ (ex. EGARCH) on a :

$$\begin{aligned}\text{grad}_{\theta} \sigma(t; \theta) &= \frac{1}{2 \sqrt{h(t; \theta)}} \text{grad}_{\theta} h(t; \theta) \\ &= \frac{1}{2 \sigma(t; \theta)} \text{grad}_{\theta} h(t; \theta) \\ \text{grad}_{\theta} \sigma(t; \theta) &= e^{\nu(t; \theta)} \text{grad}_{\theta} \nu(t; \theta) \\ &= \sigma(t; \theta) \text{grad}_{\theta} \nu(t; \theta)\end{aligned}$$

Gradient

Algorithme

- Écrire le gradient pour chaque type d'espérance, variance et log-densité conditionnelle.
- Utiliser l'équation (Eq 5) pour en déduire $\text{grad}_{\theta} u(t; \theta)$.
- Puis l'équation (Eq 4) pour en déduire $\text{grad}_{\theta} e(t; \theta)$
- Puis les équations (Eq 2) et (Eq 3) pour obtenir $\text{grad}_{\theta} l(t; \theta, y)$
- Sommer toutes ces valeurs pour calculer $\text{grad}_{\theta} \ln L(t; \theta, y)$.

Récurrence

- on observe les $y(t)$,
- on connaît la valeur du vecteur θ des paramètres du modèle,
- on calcule $m(t; \theta)$, $\sigma(t; \theta)$ puis $u(t; \theta)$ et $e(t; \theta)$ à chaque date t .

Ces valeurs dépendent non seulement de l'observation $y(t)$ à la date t **mais aussi** de ce qui a précédé (donc les $m(s; \theta)$, $\sigma(s; \theta)$, $u(s; \theta)$, $e(s; \theta)$, $s < t$).

Donc le gradient de chacune de ces quantités va aussi dépendre des “gradients du passé”

Récurrence

Exemple

Soit un modèle MA(1) “pur” gaussien. Il y a deux paramètres MA(1) et la variance σ^2 du bruit blanc gaussien :

$$\theta = \begin{pmatrix} \text{MA}(1) \\ \sigma^2 \end{pmatrix}$$

Le modèle s'écrit :

$$\begin{aligned} Y(t) &= \text{MA}(1) U(t-1; \theta) + U(t; \theta) \\ &= \text{MA}(1) U(t-1; \theta) + \sigma \varepsilon(t) \end{aligned}$$

et donc

$$m(t; \theta) = \text{MA}(1) u(t-1; \theta)$$

Récurrence

Exemple suite

Par conséquent :

$$\begin{aligned}\text{grad}_{\theta} m(t; \theta) &= \begin{pmatrix} u(t-1; \theta) \\ 0 \end{pmatrix} + \text{MA}(1) \text{grad}_{\theta} u(t-1; \theta) \\ &= \begin{pmatrix} u(t-1; \theta) \\ 0 \end{pmatrix} - \text{MA}(1) \text{grad}_{\theta} m(t-1; \theta)\end{aligned}$$

Programmation

Vecteur des paramètres

Dans la représentation informatique du modèle, les diverses valeurs des paramètres se retrouvent stockées dans divers classes C++. Pour pouvoir faire les calculs, il faut “transférer” ces diverses valeurs dans un seul “cDVector” θ .

Par exemple, considérons le modèle Cstmean + ARMA(1, 1) - GARCH(1, 1) avec résidus $St(n)$. Ce modèle comporte 7 paramètres :

- paramètres de l'espérance conditionnelle : CstMean, AR(1), MA(1) dispersés dans les 3 classes cConst, cAr et cMa.
- paramètres de la variance conditionnelle : CstVar, ARCH(1), GARCH(1) dans la classe cGarch
- paramètre de la distribution conditionnelle : n dans la classe cStudentResiduals

Programmation

Récupération

Pour récupérer les paramètres, il faut :

- 1 Calculer le nombre total de paramètres pour initialiser la taille du vecteur θ .
- 2 Récupérer la valeur de chaque paramètre dans chaque classe et les placer au bon endroit dans le vecteur θ .

En conséquence de quoi, il faut que dans la classe `cRegArchParam`, il y ait :

- 1 une fonction `int GetNParam(void)` qui retourne le nombre total de paramètres du modèle
- 2 une fonction `void RegArchParamToVector(cDVector& theDestVect)` qui récupère les valeurs et les met dans `theDestVect`

Pour le calcul de la vraisemblance, on a utilisé une classe `cRegArchValue` qui permet de stocker les calculs à chaque date t . On aurait pu se permettre de ne garder que les “`nLagMax`” précédentes valeurs, où “`nLagmax`” est le nombre maximal de retards dans modèle.

A cause de la récurrence, il va falloir faire de même lors du calcul du gradient. Il faut donc créer une classe `cRegArchGradient` qui contiennent (entre autre) les “`nGradLagMax`” gradients du passés.

Il faut donc que

- dans la classe `cRegArchParam`, il y ait une fonction *uint* `GetNLags(void)` qui retourne “`nGradLagMax`”
- que dans la classe `cRegArchGradient`, après le calcul à la date t des divers gradients, il y ait une mise à jour pour préparer le calcul à la date $t + 1$.

Hessien

Calcul

$$\text{hess}_{\theta\theta} \ln L(t; \theta, y) = \sum_{t=t_0}^T \text{hess}_{\theta\theta} l(t; \theta, y) \quad (\text{Eq 4})$$

$$\begin{aligned} \text{hess}_{\phi\phi} l(t; \theta, y) &= \frac{1}{\sigma^2()} \text{grad}_{\phi} \sigma()^t \text{grad}_{\phi} \sigma() - \frac{1}{\sigma()} \text{hess}_{\phi\phi} \sigma() \\ &\quad + \frac{\partial^2 \ln f_{\varepsilon}}{\partial x^2} (e(), \beta) \text{grad}_{\phi} e()^t \text{grad}_{\phi} e() \\ &\quad + \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(), \beta) \text{hess}_{\phi\phi} e() \quad (\text{Eq 5}) \end{aligned}$$

Hessien

Calcul suite 1

$$\begin{aligned}
 \text{hess}_{\phi\beta} l(t; \theta, y) &= \frac{1}{\sigma^2()} \text{grad}_{\phi} \sigma() {}^t \text{grad}_{\beta} \sigma() - \frac{1}{\sigma()} \text{hess}_{\phi\beta} \sigma() \\
 &+ \frac{\partial^2 \ln f_{\varepsilon}}{\partial x^2} (e(), \beta) \text{grad}_{\phi} e() {}^t \text{grad}_{\beta} e() \\
 &+ \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(), \beta) \text{hess}_{\phi\beta} e() \\
 &+ \text{grad}_{\beta} \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(), \beta) {}^t \text{grad}_{\phi} e() \quad (\text{Eq 6})
 \end{aligned}$$

Hessien

Calcul suite 2

$$\begin{aligned}
 \text{hess}_{\beta\beta} l(t; \theta, y) = & \frac{1}{\sigma^2()} \text{grad}_{\beta} \sigma() {}^t \text{grad}_{\beta} \sigma() - \frac{1}{\sigma()} \text{hess}_{\beta\beta} \sigma() \\
 & + \frac{\partial^2 \ln f_{\varepsilon}}{\partial x^2} (e(), \beta) \text{grad}_{\beta} e() {}^t \text{grad}_{\beta} e() \\
 & + \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(), \beta) \text{hess}_{\beta\beta} e() \\
 & + \text{grad}_{\beta} \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(), \beta) {}^t \text{grad}_{\beta} e() \\
 & + \text{grad}_{\beta} e() {}^t \text{grad}_{\beta} \frac{\partial \ln f_{\varepsilon}}{\partial x} (e(), \beta) \\
 & + \text{hess}_{\beta\beta} \ln f_{\varepsilon} (e(), \beta) \quad (\text{Eq 7})
 \end{aligned}$$

Hessien

Calcul suite 2

$$\begin{aligned} \text{hess}_{\theta\theta} \mathbf{e}(t; \theta) = & -\frac{1}{\sigma^2()} \text{grad}_{\theta} \sigma() {}^t \text{grad}_{\theta} u() + \frac{1}{\sigma()} \text{hess}_{\theta\theta} u() \\ & + \frac{2 u()}{\sigma^3()} \text{grad}_{\theta} \sigma() {}^t \text{grad}_{\theta} \sigma() \\ & - \frac{1}{\sigma^2()} \text{grad}_{\theta} u() {}^t \text{grad}_{\theta} \sigma() \\ & - \frac{u()}{\sigma^2()} \text{hess}_{\theta\theta} \sigma() \quad (\text{Eq 8.}) \end{aligned}$$

$$\text{hess}_{\theta\theta} u() = -\text{hess}_{\theta\theta} m() \quad (\text{Eq 9.})$$